


Mestrado em Data Science

Séries Temporais

Modelos de Séries Temporais





Conteúdo

3.1 Modelos Simples

3.2 Exponential Smoothing

3.3 ARIMA

3.4 VAR, ARDL



3.1

Modelos Simples






Método da Média

As previsões são iguais à média das observações históricas


$$\hat{y}_{t+h} = \bar{y} = (y_1 + y_2 + \dots + y_n) / n$$





Exemplo: Importância das Transformações

Aplicando o Método da Média na Série Temporal Original






Método Naive

As previsões são iguais à última observação conhecida.
Também conhecido como método persistente.

$$\hat{y}_{t+h} = y_t$$

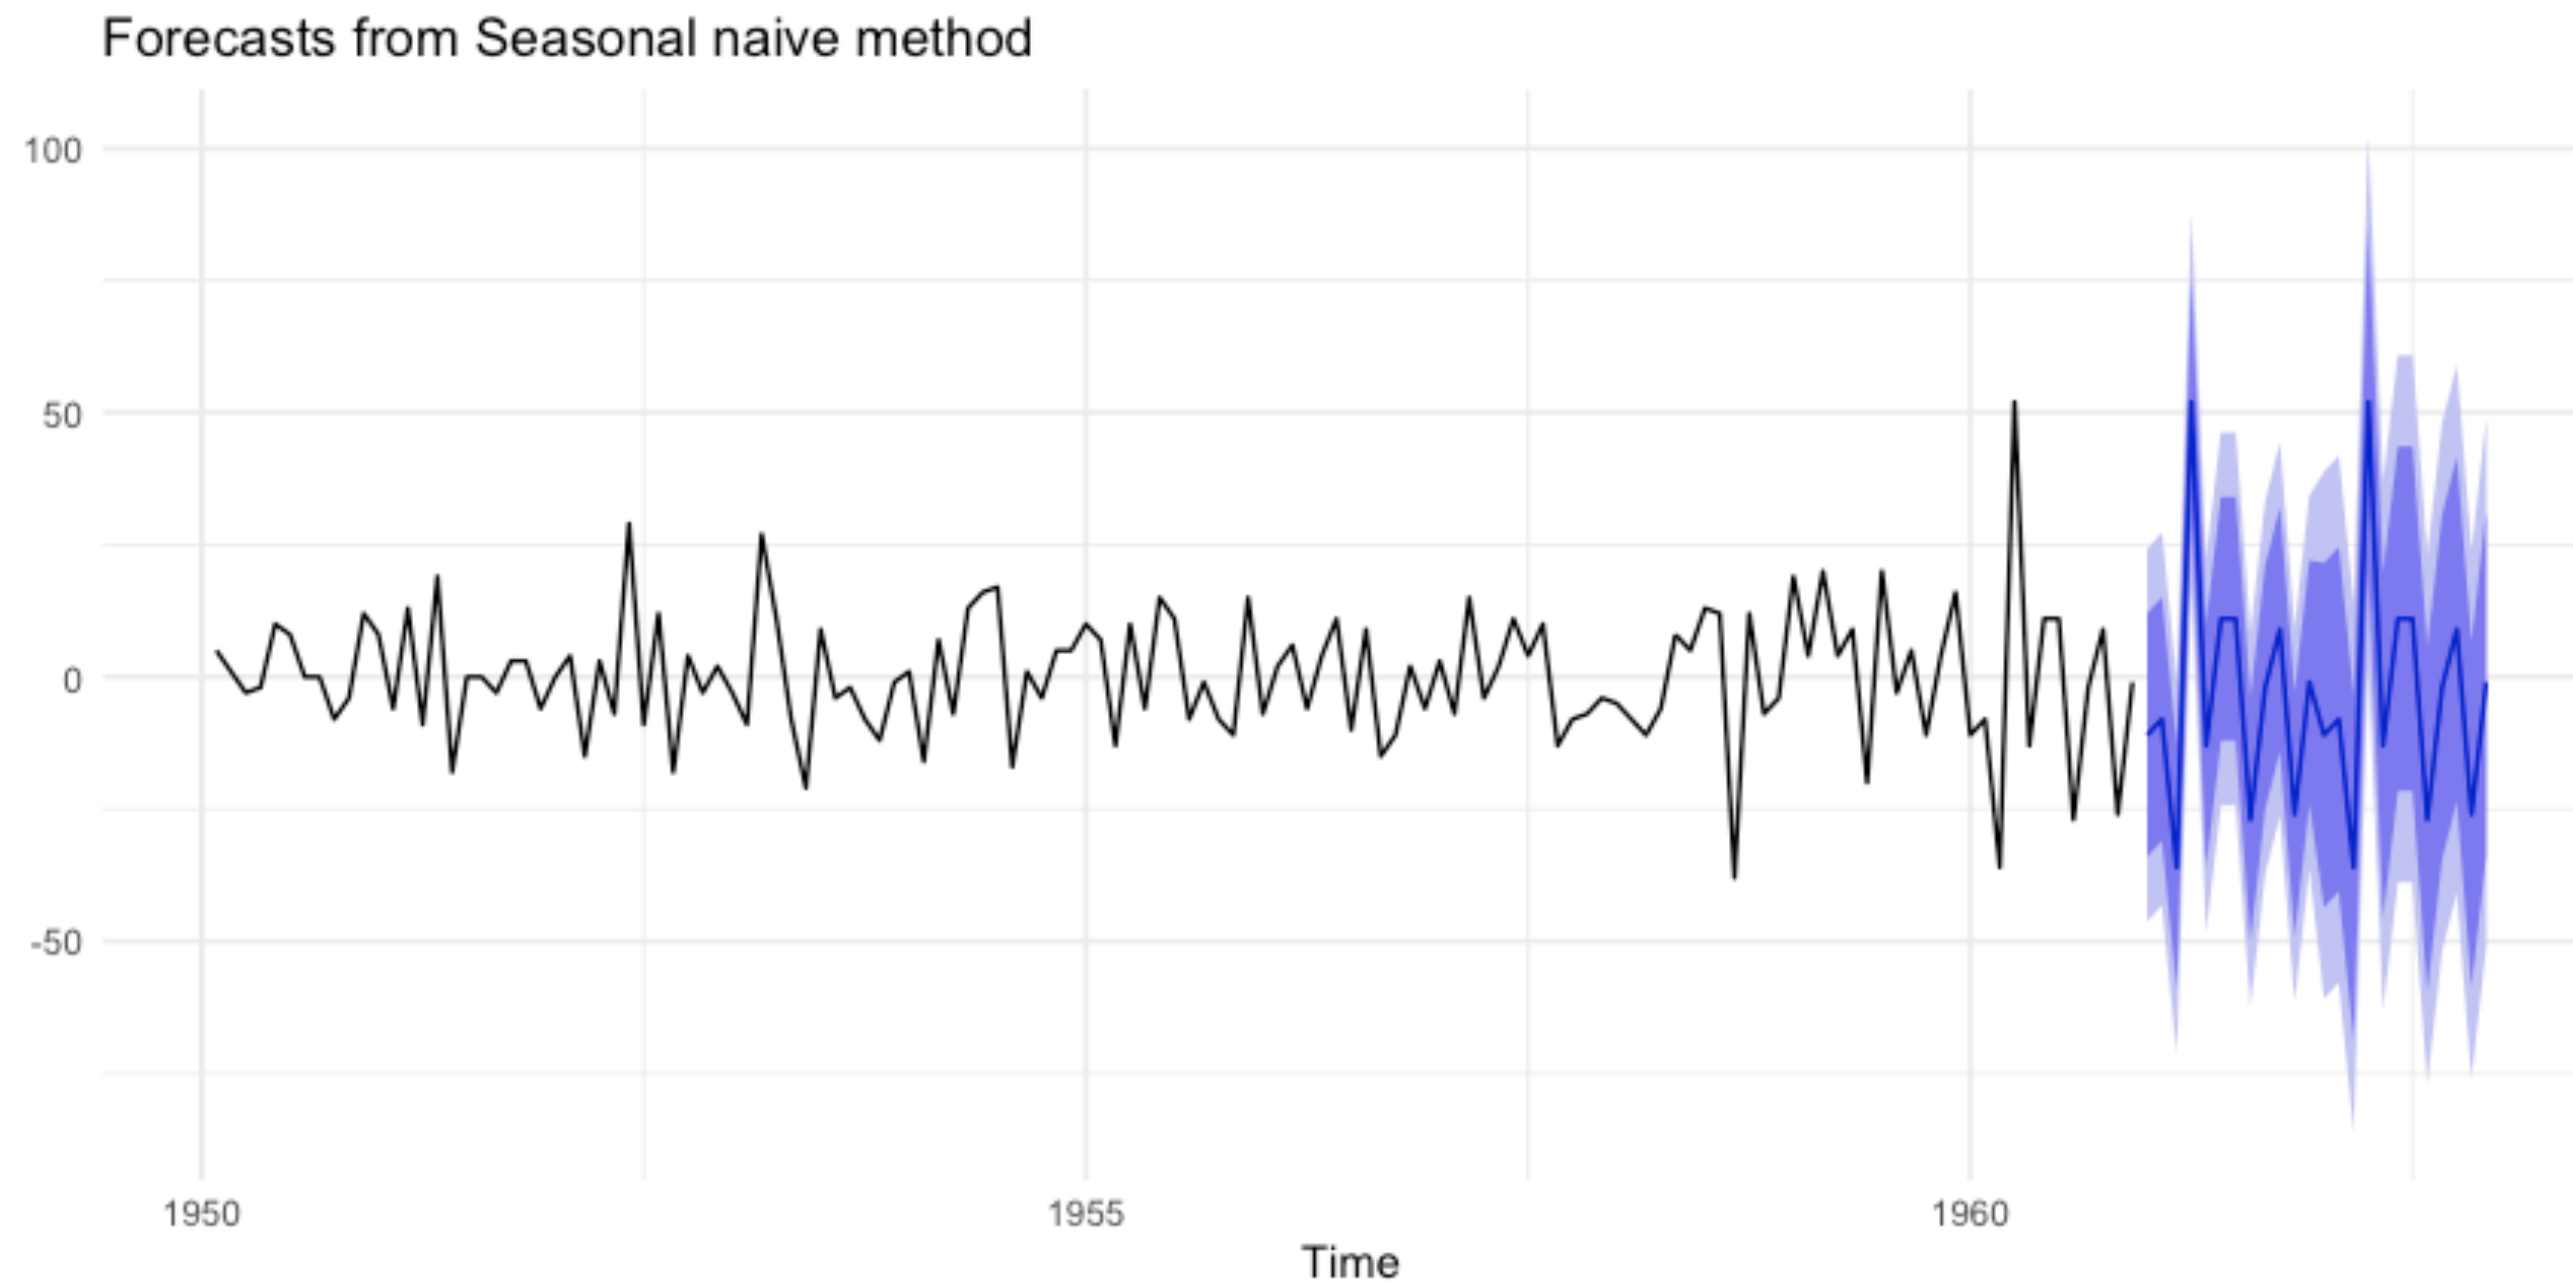




Método Sazonal Naive

As previsões são iguais à última observação conhecida do mesmo período sazonal (indicado como m).

$$\hat{y}_{t+h} = y_{t+h-m}$$





Método Drift

As previsões são iguais à última observação conhecida
mais a variação média.


$$\hat{y}_{t+h} = y_t + h \left(\frac{y_n - y_1}{n - 1} \right)$$






Método Drift

As previsões são iguais à última observação conhecida
mais a variação média.





Comparando os Métodos





3.2

Exponential Smoothing

Simple Exponential Smoothing, Método
Holt's, ETS





Simple Exponential Smoothing (SES)

Método da Média

Média das observações conhecidas

Método Naive

Usando a última observação conhecida

SES

- *Trade-off* destes dois extremos
- Promove recência das observações



Simple Exponential Smoothing (SES)


Médias Pesadas

- Médias ponderadas de observações anteriores
 - Os pesos decaem exponencialmente à medida que as observações envelhecem
- α assume um valor entre 0 e 1 que controla o decaimento
 - Podemos usar bibliotecas de software para estimar este parâmetro

$$\hat{y}_{t+1} = \alpha y_t + \alpha(1-\alpha)y_{t-1} + \alpha(1-\alpha)^2 y_{t-2} + \dots$$



Simple Exponential Smoothing (SES)





Método Holt

Estendendo SES para modelar séries temporais com tendência

$$\hat{y}_{t+h} = l_t + hb_t$$

$$l_t = \alpha y_t + (1 - \alpha)(l_{t-1} + b_{t-1})$$

$$b_t = \beta^*(l_t - l_{t-1}) + (1 - \beta^*)b_{t-1}$$

- Contém 2 parâmetros de suavização: α e β . Ambos assumem valores entre 0 e 1
- Um modelo de duas partes que considera o nível (l_t) e a inclinação (b_t) da série
- Extensão possível: tendência amortecida (*damping*)
 - Diminuindo o efeito da tendência para horizontes mais longos



Método Holt

Estendendo SES para modelar séries temporais com tendência





Mais Métodos Exponential Smoothing

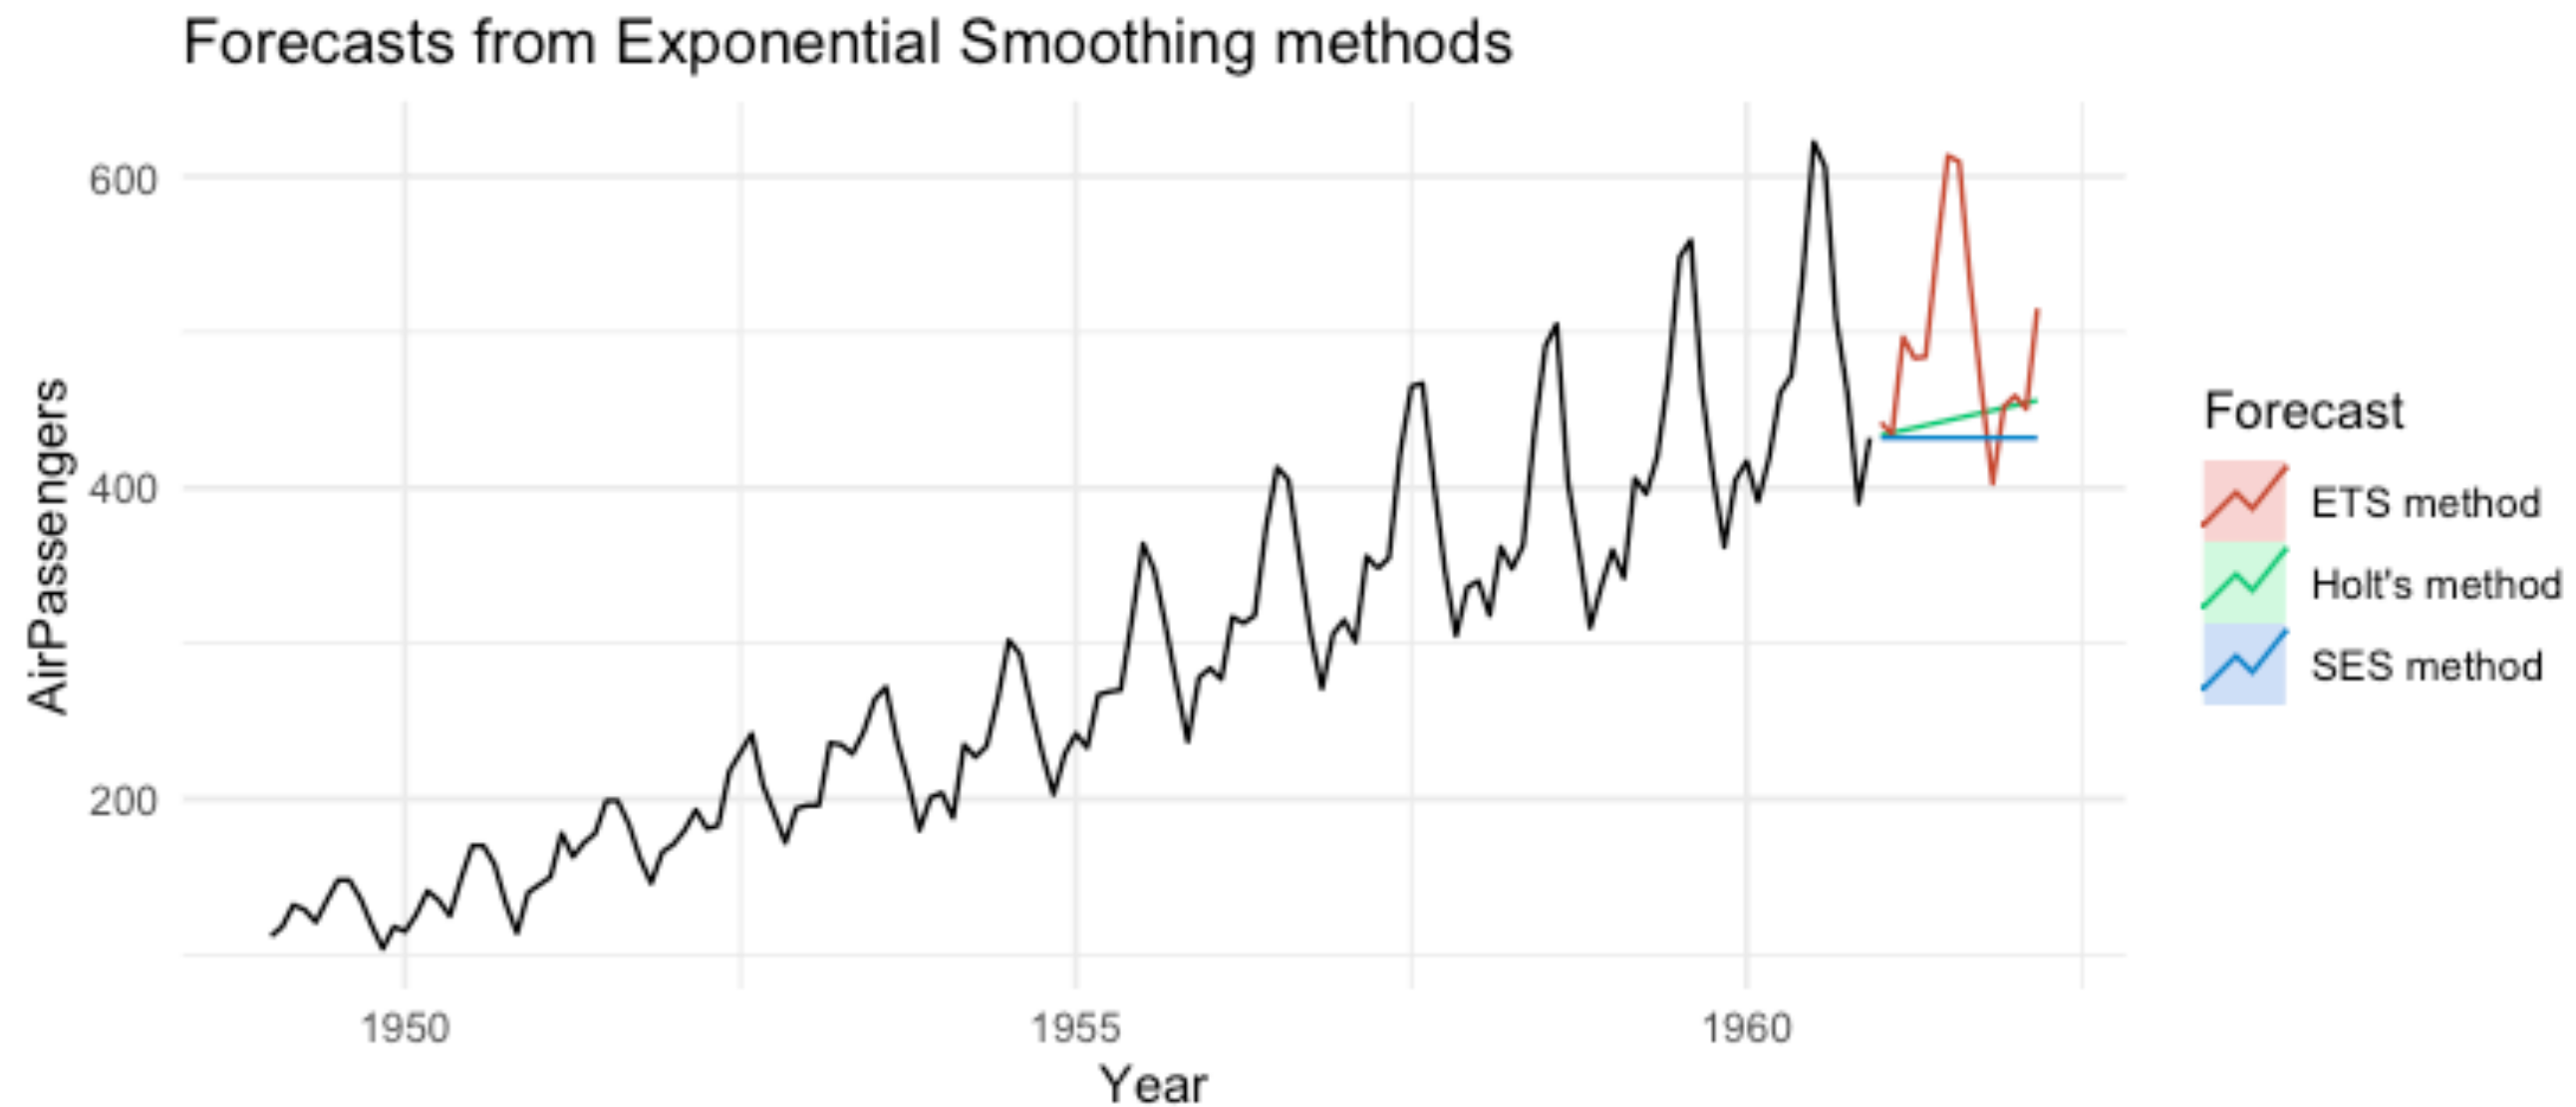
Holt-Winters

- Estende o método de Holt para capturar a sazonalidade
- Pode ser aditivo ou multiplicativo
 - Dependendo de como as variações sazonais afetam o nível da série
- Também pode ser amortecido

ETS (Error, Trend, Seasonality)

- Método *State-space*
- Considera 18 possíveis configurações
 - Seleção via Akaike's Information Criteria (AIC)

More Exponential Smoothing Methods





Métodos Exponential Smoothing

- Várias configurações possíveis
- Geralmente selecionado usando bibliotecas de software
- Eficaz na prática

Soluções Híbridas

- Pode ser combinado com métodos de aprendizagem máquina
- Parte da solução do vencedor da competição de previsão M4 (referência abaixo)
 - A suavização exponencial foi usada para normalizar séries temporais
 - Deep learning foi usado para as previsões

Smyl, Slawek. "A hybrid method of exponential smoothing and recurrent neural networks for time series forecasting." *International Journal of Forecasting* 36.1 (2020): 75-85.



3.3 **ARIMA**

AR, MA, ARMA, ARIMA, ARIMAX





Método Auto-Regressivo (AR)

Regressão Múltipla

A variável objetivo é modelada de acordo com uma combinação linear de variáveis explicativas

AR(p)

- Regressão Múltipla para séries temporais
- A variável objetivo representa o próximo valor da série
- As variáveis explicativas são observações passadas
- p representa a ordem do modelo:
 - Número de observações passadas a usar

$$y_t = c + \sum_{i=1}^p \phi_i y_{t-i} + \epsilon_t$$



Método Auto-Regressive (AR)

Equação do Modelo

$$y_t = c + \sum_{i=1}^p \phi_i y_{t-i} + \epsilon_t$$

- p : número de observações passadas (lags)
- ϕ : parâmetros do modelo
- ϵ : termo de erro
- c : termo constante



Método Moving-Average (MA)

Moving Average

Não confundir com o processo de médias móveis.

MA(q)

- Parecido com AR(p), mas usa erros passados como variáveis explicativas
- **q** representa a ordem do modelo

MA(q) leva em conta os erros aleatórios que ocorreram nos últimos q pontos

$$y_t = c + \sum_{i=1}^q \theta_i \epsilon_{t-i} + \epsilon_t$$



Método Moving-Average (MA)

Equação MA(q)

$$y_t = c + \sum_{i=1}^q \theta_i \epsilon_{t-i} + \epsilon_t$$

- q : número de observações passadas (lags)
- Θ : parâmetros do modelo
- ϵ : termo de erro
- c : termo constante



Método Auto-Regressive Moving-Average (ARMA)

Combinação de AR(p) com MA(q) (Box-Jenkins)

ARMA(p, q) = AR(p) + MA(q)

$$y_t = c + \sum_{i=1}^p \phi_i y_{t-i} + \sum_{i=1}^q \theta_i \epsilon_{t-i} + \epsilon_t$$

Definido para séries temporais estacionárias



Auto-Regressive Integrated Moving-Average (ARIMA)

Adicionando um passo de integração

ARIMA(p , d , q)

- d é um parâmetro de integração de ordem d
- Aplicar d transformações de diferenciação (até obter estacionaridade)
- Depois, aplicar ARMA(p , q) à série transformada

Casos Especiais

ARIMA(0,0,0): Ruído branco

ARIMA(0,1,0) with $c = 0$: Passeio aleatório (Random Walk)

ARIMA(p ,0,0): Auto-regressão

ARIMA(0,0, q): Moving-average



Auto-Regressive Integrated Moving-Average (ARIMA)

ARIMAX

- ARIMA com variáveis explicativas
- Útil quando existem variáveis adicionais relevantes para o problema



SARIMA e Auto ARIMA

SARIMA (Seasonal ARIMA)

- ARIMA pode ter termos sazonais
- A estrutura sazonal é *idêntica à não sazonal* e para capturar padrões sazonais
- $\text{ARIMA}(p,d,q)(P,D,Q)_m$


Seleção da configuração do ARIMA

- Visualizar auto-correlações and determinar onde esta é significativa
- ... Ou deixar que software faça isso por si
- Muitas implementações de Auto ARIMA, tanto em R como em Python

```
from pmdarima.arima import auto_arima  
model = auto_arima(series)
```



Auto ARIMA





3.4


VAR, ARDL





Séries Temporais Multivariadas

- Séries Temporais podem conter várias variáveis
 - Estas são chamadas de séries multivariadas
 - As variáveis adicionais podem ser de interesse para previsão ou podem simplesmente ser usadas como variáveis explicativas






Vector Auto-Regression (VAR)

VAR é um método para séries temporais multivariadas


- “Auto-Regression” porque cada variável é modelada de acordo com as suas observações passadas e as observações passadas das restantes variáveis





Auto-Regressive Distributed Lag (ARDL)

- Parecido com VAR, mas apenas uma das variáveis é de interesse para previsão
 - As restantes podem ser usadas como variáveis explicativas



Modelos de Séries Temporais

Vitor Cerqueira

[https://www.linkedin.com/in/vcerq/
cerqueira.vitormanuel@gmail.com](https://www.linkedin.com/in/vcerq/cerqueira.vitormanuel@gmail.com)

